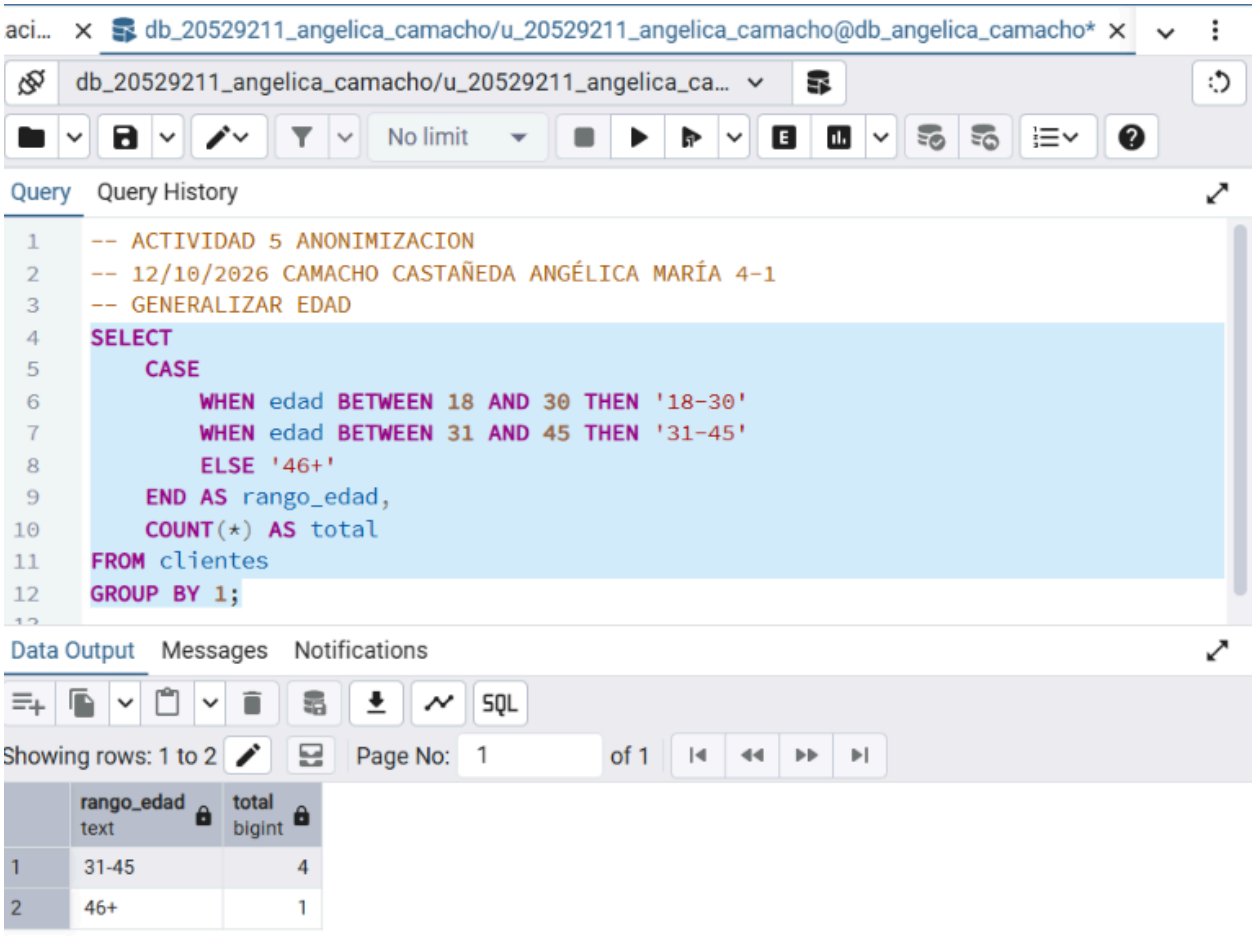
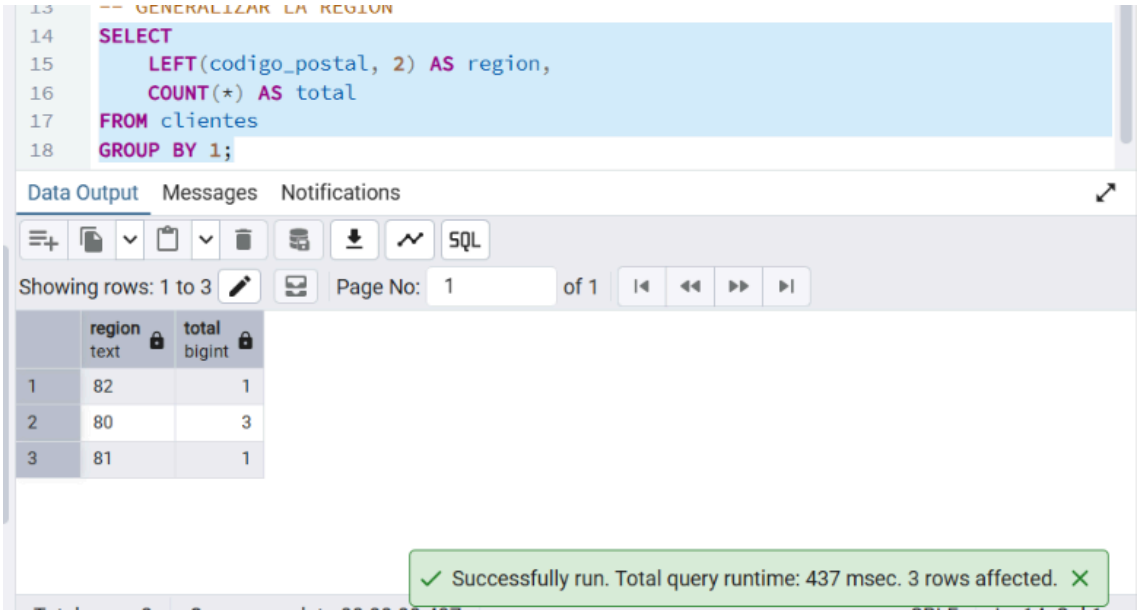
12. Actividad 5 — Anonimización (anonymization)

El área de dirección solicita información estadística. No necesita conocer a los clientes individualmente. El objetivo es generar información agregada y reducir el riesgo de reidentificación.

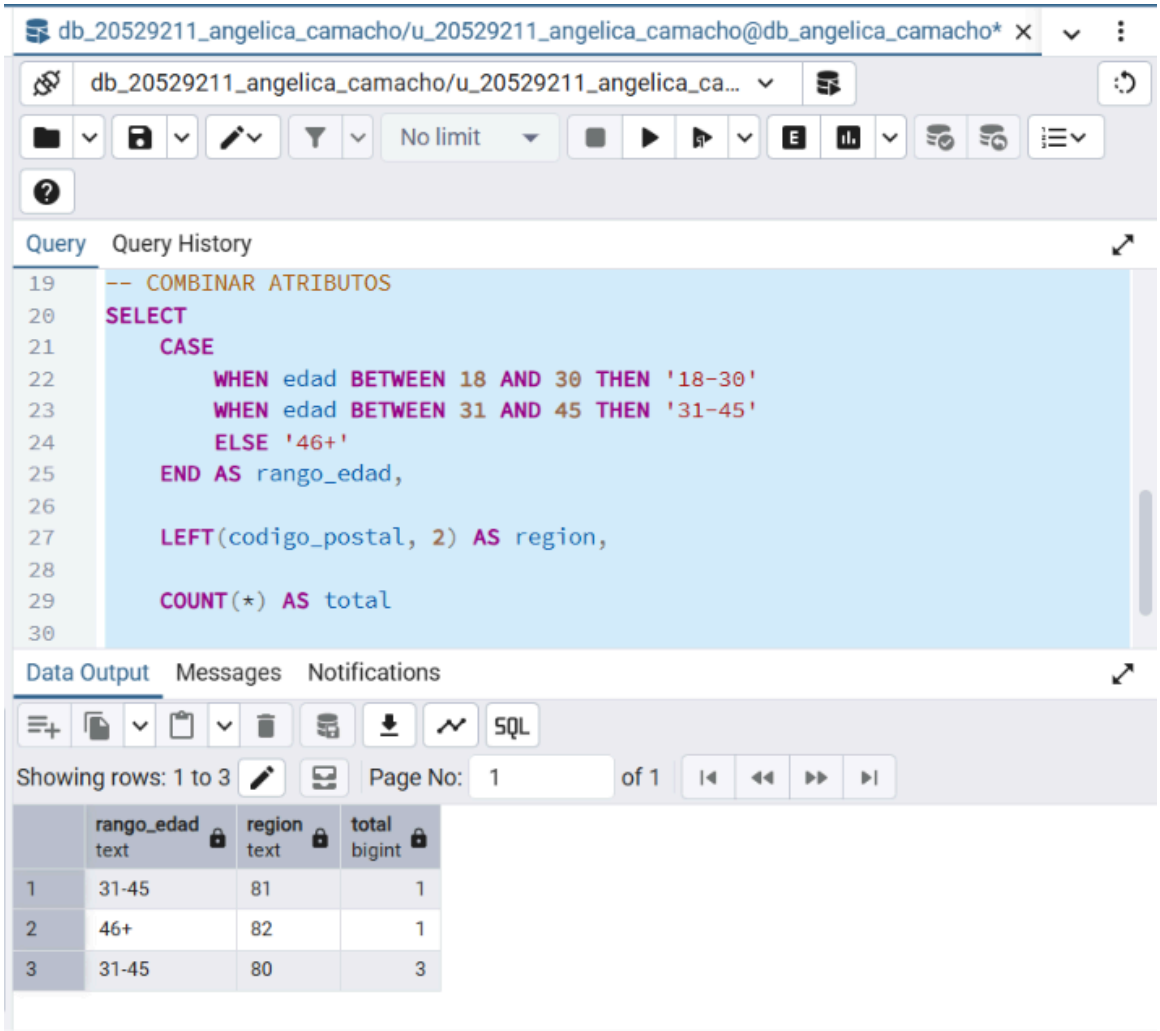
Generalizar la edad



Generalizar la región



Combinar atributos



Suprimir grupos pequeños

Query | Query History

```sql
-- SUPRIMIR GRUPOS PEQUEÑOS
SELECT
    CASE
        WHEN edad BETWEEN 18 AND 30 THEN '18-30'
        WHEN edad BETWEEN 31 AND 45 THEN '31-45'
        ELSE '46+'
    END AS rango_edad,

    LEFT(codigo_postal, 2) AS region,

    COUNT(*) AS total

FROM clientes
GROUP BY 1, 2
HAVING COUNT(*) >= 5;
```

Data Output | Messages | Notifications

SQL

rango_edad text	region text	total bigint

Reto de reducir aún más el riesgo de identificación

```sql
-- RETO (REDUCIR EL RIESGO DE REIDENTIFICACIÓN)
SELECT
    CASE
        WHEN edad BETWEEN 18 AND 35 THEN '18-35'
        ELSE '36+'
    END AS rango_edad,
    LEFT(codigo_postal, 1) AS region,
    COUNT  (*) AS total
FROM clientes
GROUP BY 1,2
HAVING COUNT (*) >=10;

```

Data Output | Messages | Notifications

SQL

rango_edad text	region text	total bigint

ACTIVIDAD 7: Retención de datos

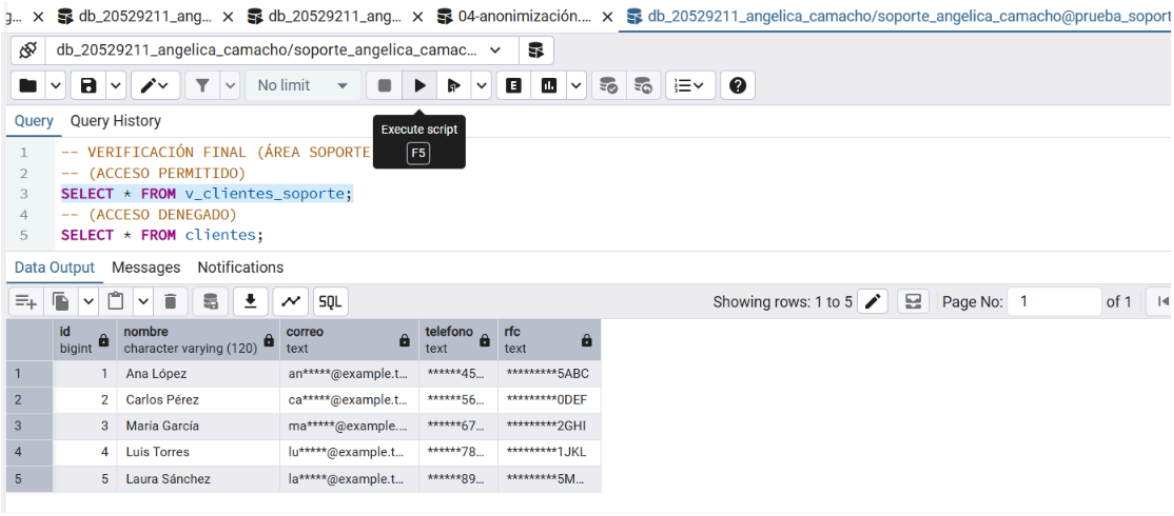
```
59  -- ACTIVIDAD 7: RETENCIÓN DE DATOS
60  SELECT *
61  FROM clientes
62  WHERE fecha_alta <
63        CURRENT_DATE - INTERVAL '5 years';
```

Data Output | Messages | Notifications

id [PK] bigint	nombre character varying (120)	correo character varying (150)	telefono character varying (20)	rfc character varying (13)	edad integer	ciudad character varying (80)	codigo_postal character varying (10)	fecha_alta date

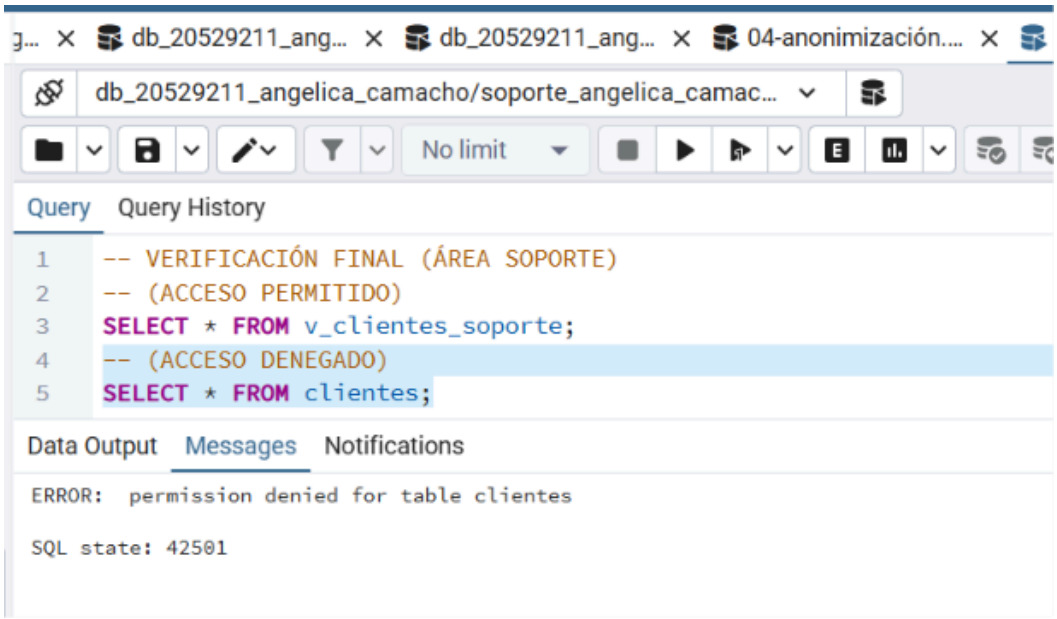
Total rows: 0 | Query complete 00:00:00.817 | CRLF | Ln 60, Col 1

Verificación final (área de soporte) (acceso permitido)

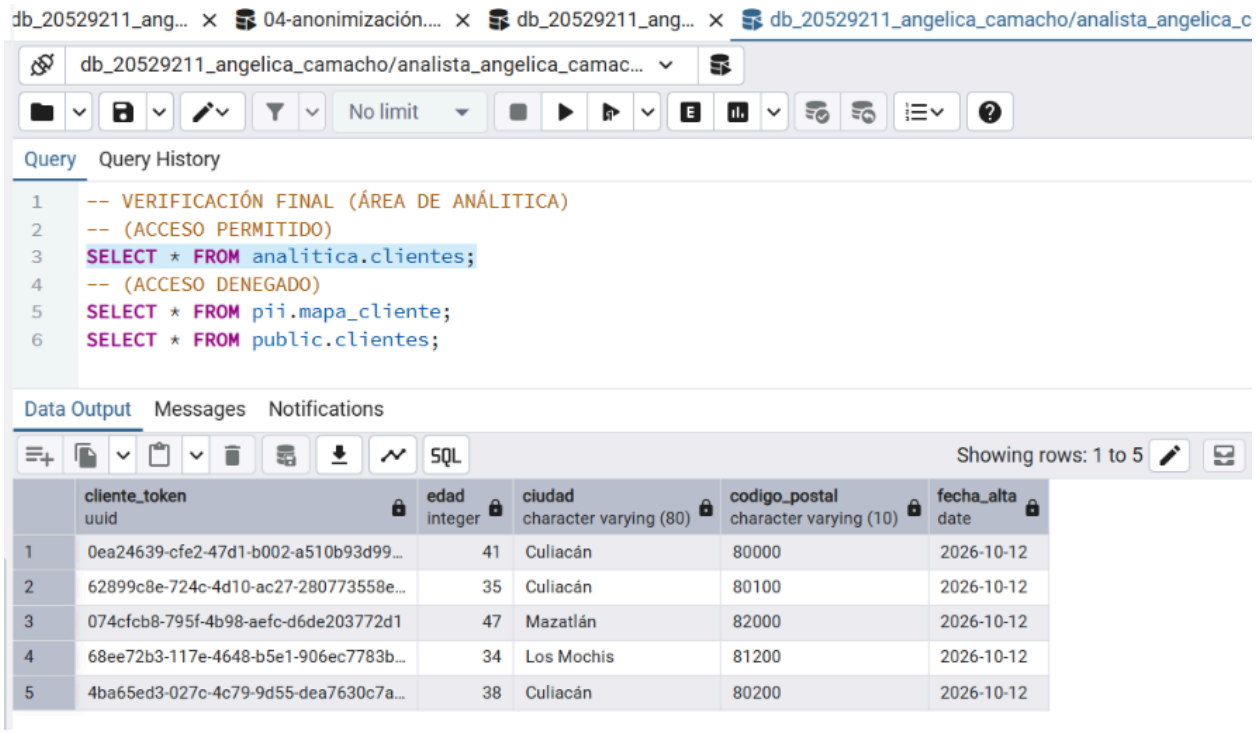


	id bigint	nombre character varying (120)	correo text	telefono text	rfc text
1	1	Ana López	an*****@example.t...	******45...	*********5ABC
2	2	Carlos Pérez	ca*****@example.t...	******56...	*********0DEF
3	3	María García	ma*****@example....	******67...	*********2GHI
4	4	Luis Torres	lu*****@example.t...	******78...	*********1JKL
5	5	Laura Sánchez	la*****@example.t...	******89...	*********5M...

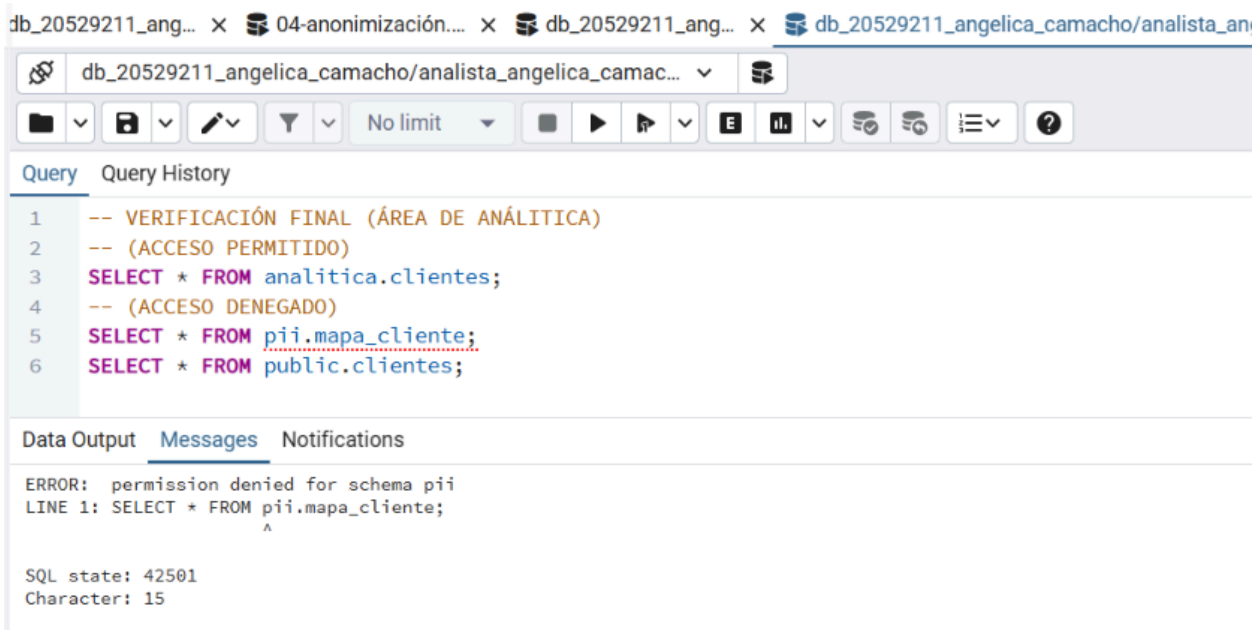
Verificación final (área de soporte) (acceso no permitido)

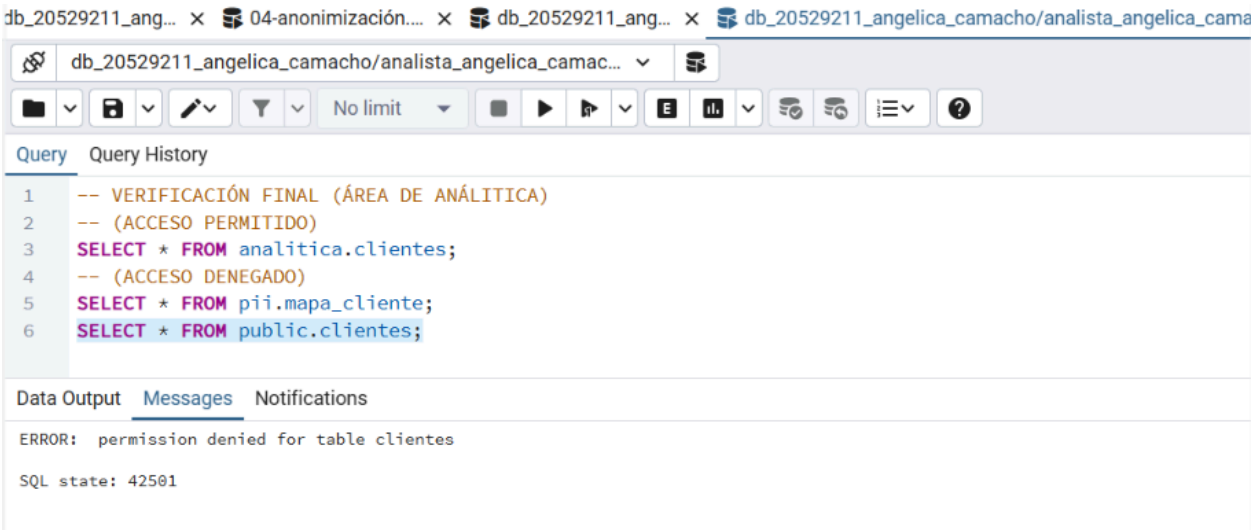


Verificación de final (área de analitica) (acceso permitido)



Verificación final (área de analitica) (acceso no permitido)





13. Actividad 6 - Análisis del riesgo de reidentificación

Preguntas

¿Qué identificadores directos fueron eliminados? El nombre, correo, teléfono, RFC y ID.

¿Qué cuasi-identificadores permanecen? El rango de la edad y la región

¿Qué combinaciones de atributos podrían reducir el anonimato? La combinación del rango edad y la región, también con el código postal, estos tres juntos como mencioné, reducen el grupo de personas que se pueden identificar con estas características.

¿Qué sucede cuando un grupo contiene pocos registros? El usuario se vuelve muy sencillo de identificar, y al tener muy pocas características (datos) se puede reidentificar y deducir sus demás datos.

¿Qué atributos debería generalizarse? La edad en rangos más grandes y el código postal ya sea asignando una región, ciudad o estado.

¿Qué información debería suprimirse? Los identificadores directos y los grupos que tienen menos de 5 registros, los identificadores por que revelan información del usuario y los grupos que tienen pocos registros por que se vuelven fácil de reidentificar.

¿Es correcto afirmar que el conjunto de datos es “100 % anónimo”? ¿Por qué? No, ya que aunque se eliminen los identificadores directos, se generalicen datos, sigue habiendo cuasi-identificadores que en conjunto con otros datos pueden ayudar a la reidentificación, ya que el k-anonimato reduce el riesgo, más no lo elimina.